華中科技大學

计算机视觉

实验报告

实验二：Fashion-MNIST

卷积分类、结构先验与扩散生成

学院：电子信息与通信学院

专业班级：电信 2303 班

姓名：赵浩宇

学号：U202314553

指导教师：王兴刚、廖振宇、闫增强

目录

1 实验任务与模型设置 **2**
1.1 结构与参数量 2

2 卷积分类与结构先验检验 **2**
2.1 原图上的受控比较 2
2.2 固定像素置换实验 4

3 扩散模型实现与训练 **6**

4 生成质量评价与结论 **7**

参考文献 **7**

1 实验任务与模型设置

Fashion-MNIST 含 28×28 灰度服饰图像和 10 个类别 [1]。本实验沿用实验 1 的官方训练集固定划分（50,000 训练、10,000 验证；split seed 42），官方测试集仅用于选定验证集检查点后的最终评价。分类模型均使用 $[0,1]$ 输入、不做随机增强；训练 30 epoch、batch size 128、Adam 学习率 10^{-3}、weight decay 0，训练种子为 42、123、2026。每个实验条件报告三种子测试准确率均值与样本标准差。

1.1 结构与参数量

MLP 沿用实验 1 的 $784 \to 128 \to 10$ ReLU 基线。CNN 使用两组 3×3 卷积、ReLU 与 2×2 最大池化，随后展平并接全连接分类头。尺寸按单样本列出；卷积参数包含 bias，ReLU、池化和展平不含参数。

表 1：网络层输出尺寸与可训练参数量

模型	层	输出尺寸	参数量
MLP	Flatten	784	0
	Linear $784 \to 128$ + ReLU	128	100,480
	Linear $128 \to 10$	10	1,290
	总计		**101,770**
CNN	输入	$1 \times 28 \times 28$	0
	Conv $1 \to 32$, 3×3, pad 1 + ReLU	$32 \times 28 \times 28$	320
	MaxPool 2×2	$32 \times 14 \times 14$	0
	Conv $32 \to 64$, 3×3, pad 1 + ReLU	$64 \times 14 \times 14$	18,496
	MaxPool 2×2	$64 \times 7 \times 7$	0
	Flatten	3,136	0
	Linear $3136 \to 128$ + ReLU	128	401,536
	Linear $128 \to 10$	10	1,290
	总计		**421,642**

CNN 参数量约为 MLP 的 4.14 倍，其中全连接 $3136 \to 128$ 层占 CNN 总参数约 95.2%。因此本实验比较的是两种完整模型方案，性能差异不能只归因于卷积运算本身。

2 卷积分类与结构先验检验

2.1 原图上的受控比较

分类对照在每种子上使用相同的数据划分、训练轮数、优化器、批量大小与检查点规则；每轮按验证准确率保存最佳模型，测试集不参与选模。CNN 参数更多，但在当前设置下耗时与 MLP 接近。表 2 给出汇总；耗时是当前服务器上的单次运行墙钟记录，不能直接视为跨硬件的计算复杂度。

表 2：原图与像素置换图上的分类结果（3 个种子，均值 ± 样本标准差）

输入	模型	参数量	测试准确率	运行时间（秒）
原图	MLP	101,770	0.8840 ± 0.0012	130.4 ± 1.0
原图	CNN	421,642	0.9189 ± 0.0034	132.3 ± 0.5
置换图	MLP	101,770	0.8859 ± 0.0010	151.9 ± 1.5
置换图	CNN	421,642	0.8788 ± 0.0023	152.4 ± 0.2

原图上 CNN 比 MLP 高 3.48 个百分点；逐种子差值为 3.11、3.35、3.99 个百分点，方向一致。CNN 的召回率优势并非来自每一类都等幅提升：seed 42 上 Coat 与 Shirt 召回率分别为 0.822、0.740，仍较易与其他上装混淆；混淆矩阵中 Shirt 被判为 T-shirt/top 110 张，Coat 被判为 Pullover 80 张、被判为 Shirt 61 张。图 1 展示训练过程，图 2 给出按测试索引先后出现的错误样本，未人工挑选成功案例。

为便于复核汇总统计，表中列出每个条件对应的三个独立训练种子结果。均值与样本标准差由这些原始准确率按条件分别计算；不同种子改变模型初始化和训练随机性，数据划分与像素置换保持固定。CNN 三个种子均优于 MLP，但三次差值（3.11–3.99 个百分点）并不相同。样本标准差描述有限的训练随机性，不是总体置信区间，三个种子不足以支持很强的显著性推断。训练曲线仅绘制 seed 42，是训练动态的代表性实例，表格则汇总三个种子。

表 3：各分类条件的逐种子测试准确率

输入	模型	seed 42	seed 123	seed 2026
原图	MLP	0.8853	0.8839	0.8829
原图	CNN	0.9164	0.9174	0.9228
置换图	MLP	0.8860	0.8849	0.8868
置换图	CNN	0.8766	0.8786	0.8811

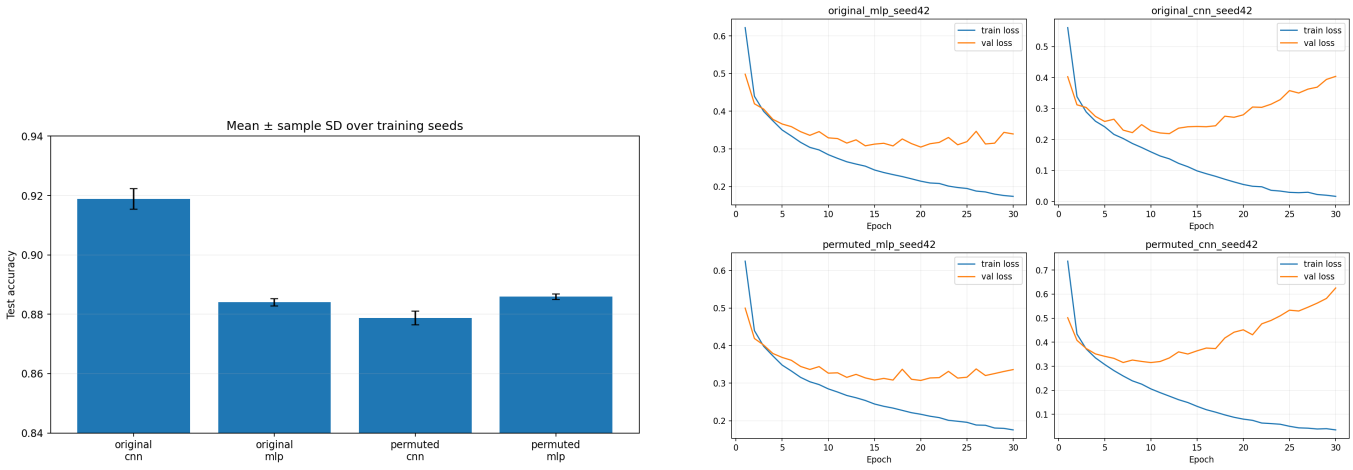


图 1：左：四种条件的测试准确率均值与样本标准差；右：seed 42 的训练/验证损失曲线（四个模型条件）

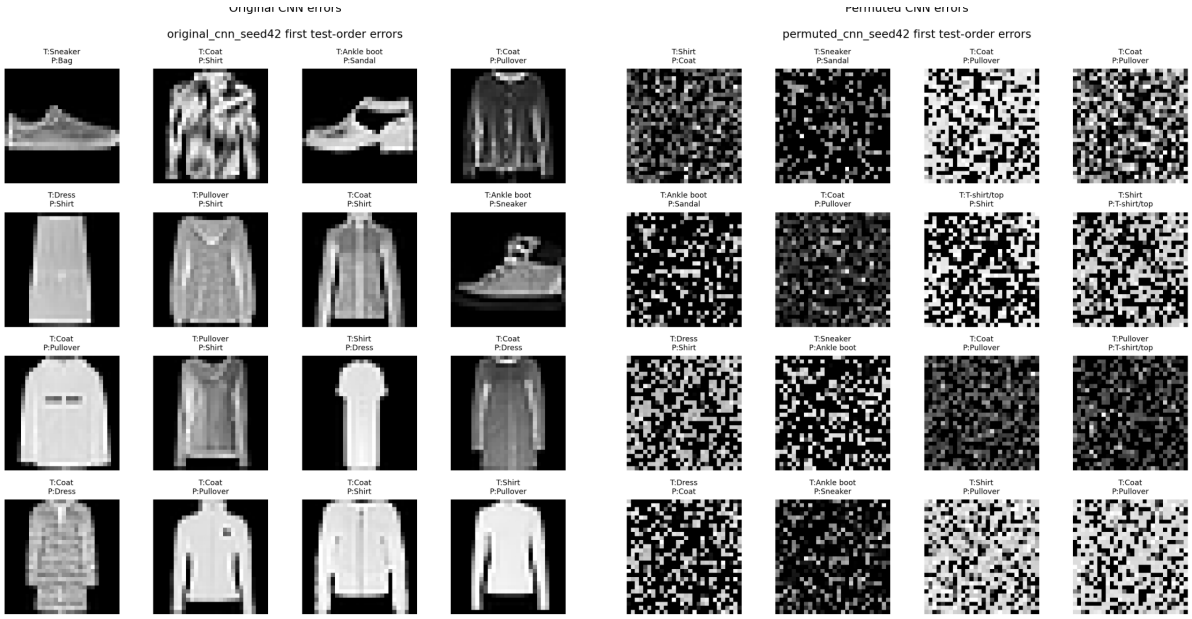


图 2: seed 42 的 CNN 测试错误：上为原图、下为像素置换图，各展示按测试索引顺序出现的前 16 个错误

为了不只呈现 CNN 的错误，图 3 给出相同种子下 MLP 的原图与置换图错误样本。错误图按照测试集索引由小到大展示前 16 个误分类，不按类别或置信度筛选。原图模式下模型仍能利用轮廓区分多数鞋类和包类，但上装类别边界模糊；置换后像素图失去可读的空间轮廓，因此图像本身不再支持直观语义归因，需结合混淆矩阵和召回率判断。

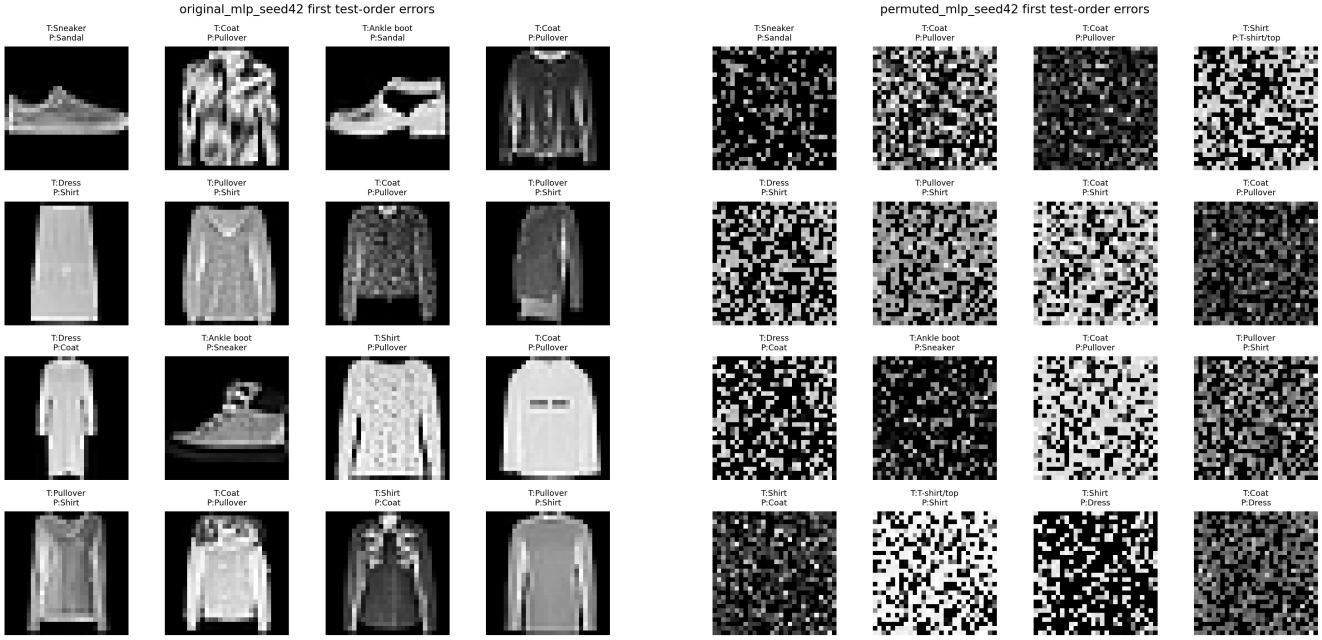


图 3: seed 42 的 MLP 测试错误：上为原图，下为置换图。每行均按测试索引顺序展示前 16 个错误

2.2 固定像素置换实验

使用 seed 20261024 生成一个 784 像素的固定置换，并将完全相同的置换用于训练、验证和测试图像。置换保留每张图的像素值与标签，只打乱像素的邻接关系。对照结果显示：置换使 CNN 测试准确率从 0.9189 降至 0.8788（下

降 4.01 个百分点）；MLP 则从 0.8840 变为 0.8859（上升 0.19 个百分点，量级与种子波动相近）。置换后 CNN 比 MLP 低 0.71 个百分点；原图上 CNN 对 MLP 的 3.48 个百分点优势因此反转。这支持 CNN 的原图优势部分依赖局部空间结构先验，而非单纯由“参数更多”造成。

该结论有边界：这里只测试一个固定置换、三个训练种子；不同置换可能造成不同难度，且 CNN 仍达到 87.88% 准确率，说明全局统计仍包含类别信息。置换条件训练时间比原图高约 20 秒（两种模型均如此），该差值可能受到输入置换处理和运行环境影响；模型间训练预算相同，但墙钟时间不应被解释为纯前向计算成本。figs. 2 and 4 对照 seed 42 的混淆矩阵与错误样本，可见原图错误主要仍是服饰间的语义近邻，而置换图样本已不具备直观轮廓。

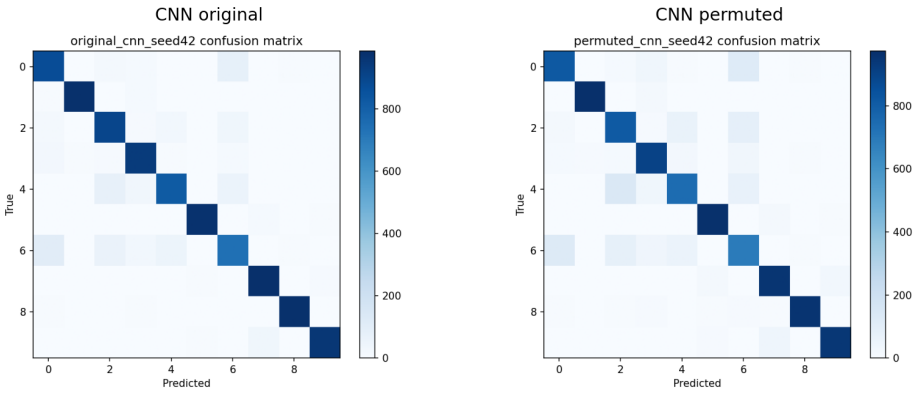


图 4: CNN 测试混淆矩阵：左为原图，右为置换图。类别编号按 Fashion-MNIST 标准顺序 0–9

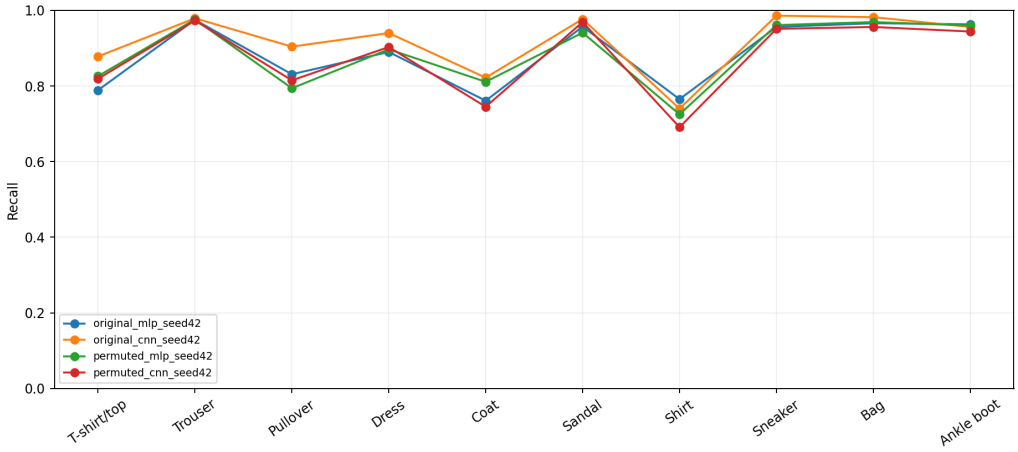


图 5: 四种输入/模型条件下的逐类召回率（seed 42）。各类别测试样本数相同，召回率可直接横向比较

逐类结果进一步细化了结构先验的作用。原图上 CNN 相对 MLP 在 T-shirt/top、Pullover 和 Coat 的召回率分别高约 8.9、7.3 和 6.1 个百分点，但 Shirt 低约 2.5 个百分点，Ankle boot 低约 0.7 个百分点。像素置换后，CNN 相对其原图的召回下降较多的类别包括 Pullover（约 8.9 个百分点）、Coat（约 7.7 个百分点）、T-shirt/top（约 5.9 个百分点）和 Shirt（约 4.9 个百分点）。整体准确率会掩盖类别差异；卷积局部先验主要改善若干视觉结构相似的服饰类别，并非对所有标签同等有效。

3 扩散模型实现与训练

本实验实现无条件 DDPM：给训练图像 x_0 按预设噪声日程逐步加噪，令 $\alpha_t = 1 - \beta_t$、$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$，则

$$x_t = \sqrt{\bar{\alpha}_t} x_0 + \sqrt{1 - \bar{\alpha}_t}\, \epsilon, \qquad \epsilon \sim \mathcal{N}(0, I).$$

去噪器接收 x_t 和时间步 t（经时间步条件嵌入），学习预测噪声，目标为

$$\mathcal{L}_\epsilon = \mathbb{E}_{x_0, t, \epsilon} \left[\| \epsilon - \epsilon_\theta(x_t, t) \|_2^2 \right].$$

单步反向更新按 DDPM 噪声预测形式计算

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t) \right) + \sigma_t z,$$

其中 $z \sim \mathcal{N}(0, I)$（最后一步不再加噪）。完整采样从固定高斯噪声 x_T 出发，按 $t = T, \ldots, 1$ 迭代至 x_0[2]。模型不接收服饰类别条件。

表 4: 扩散模型训练与采样记录

训练样本数	50,000（固定训练子集）
基础通道数 / 参数量	32 / 148,673
扩散步数 / epoch	100 / 30
设备 / 训练种子	CUDA GPU / 42
训练噪声 MSE	0.4021（第 1 轮）→ 0.1402（第 30 轮）
训练时间	129.58 秒
采样种子 / 轨迹噪声种子	20261024 / 314159
采样批量 / 记录时间	100 张 / 0.158–0.205 秒

训练日志中的噪声预测 MSE 总体下降并在约 0.14 附近趋缓；没有单独的扩散验证集损失，因此该曲线只说明训练目标被优化，不能单独证明生成分布质量。两份采样记录分别给出 0.158 秒和 0.205 秒/100 张，报告保留该实测范围（约 1.58–2.05 ms/张），反映短时 GPU 采样计时对同步与计时区间较敏感。训练种子、采样种子、轨迹噪声种子及初始噪声张量均有记录，固定噪声保存在扩散结果文件中。

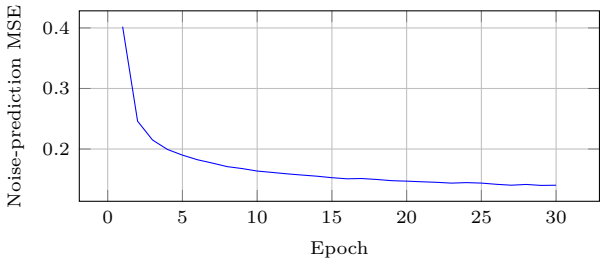


图 6: 扩散模型训练损失

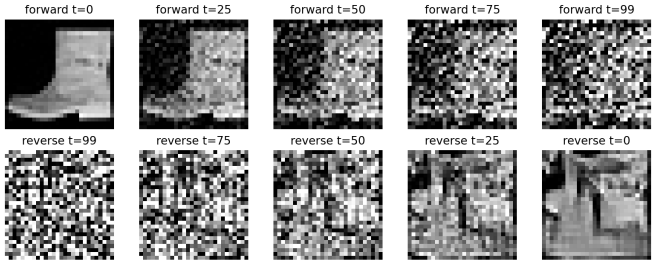


图 7: 固定样本的前向加噪与反向去噪过程

4 生成质量评价与结论

图 8 展示固定采样种子生成的随机样本网格，非人工筛选的成功样本。训练集最近邻（图 10）从固定训练子集每 5 张取 1 张（10,000 张）中按原始像素 L_2 距离搜索；该检查可以发现明显像素级复制，但不是感知距离，也不能排除子集之外的近邻。图 9 使用独立训练的 CNN 作为类别代理评价器，而非人工真值；100 张样本被预测为 Bag 86、Shirt 5、T-shirt/top 3、Trouser 3、Sandal 2、Pullover 1，其余四类为 0，仅覆盖 6/10 类。类别覆盖严重偏斜。代理分类器对这 100 张生成图的平均最大类别概率为 0.924；最低置信度四分位（25 张）的置信度均值为 0.730，范围为 0.478–0.900。高平均置信度与 86% 样本集中在 Bag 并存，说明单看置信度会把模式塌缩误读为高质量。代理分类器只在真实 Fashion-MNIST 图像上训练，遇到模糊或异常生成图可能过度自信；类别计数是近似覆盖诊断，不是生成标签真值。最低置信度四分位的 25 张（图 11）也全部展示，避免只呈现看起来较成功的样本。

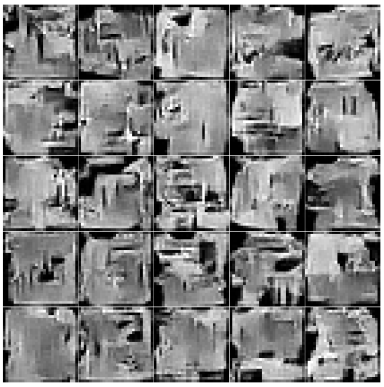


图 8: 固定初始噪声生成的随机样本网格

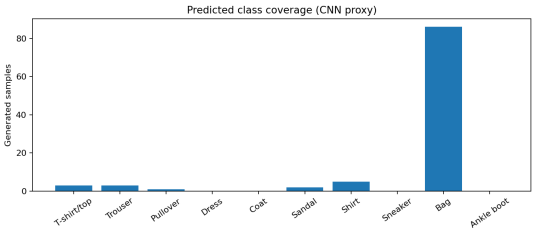


图 9: 100 张样本的代理类别覆盖

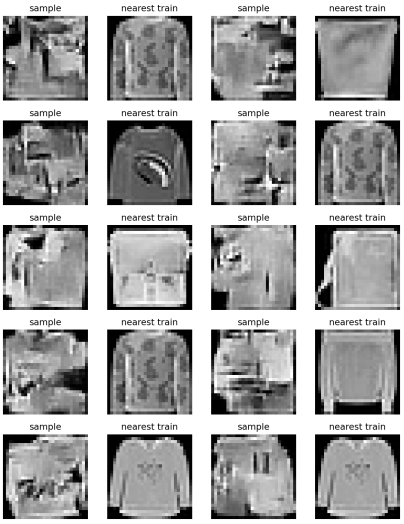


图 10: 生成样本及训练子集像素距离最近邻

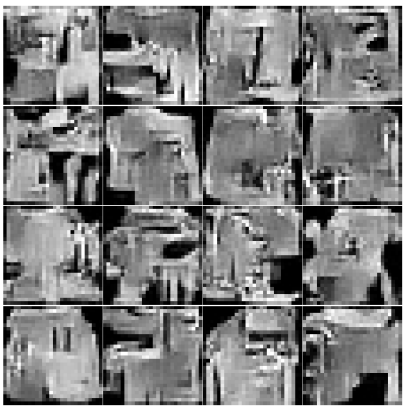


图 11: 固定批次中代理置信度最低的 25 张

样本网格仍模糊且类别集中到 Bag，最近邻未显示清晰复制。扩散流程实现完整，但 30 轮训练未获得清晰、类别覆盖充分的样本。最近邻检索只覆盖固定 50,000 张训练样本中每隔五张取一张的 10,000 张子集，并在原始像素空间使用 L_2 距离；它不能排除语义近邻或子集外的复制。生成任务无条件，类别统计依赖代理分类器；同时未设置独立的生成验证指标，也未比较网络规模、噪声日程或采样器。训练损失下降只能说明噪声回归目标得到优化，不能替代生成分布质量评价。分类结果支持 CNN 优势依赖原图局部空间结构；结论限于本实验模型、单一置换与三个种子。

参考文献

[1] H. Xiao et al. Fashion-MNIST. arXiv:1708.07747, 2017.

[2] J. Ho et al. Denoising Diffusion Probabilistic Models. NeurIPS, 2020.