華中科技大學

课程后编程实验报告

从零训练 MNIST 扩散模型

学院: 电子信息与通信学院

专业班级: 电信 2303 班

姓名: 赵浩宇

学号: U202314553

指导教师: 王兴刚

目录

1 实验目的与数据 **2**

2 方法与软件实现 **2**

2.1 前向加噪 2

2.2 去噪网络与损失 2

2.3 反向 ancestral sampling 2

3 实验结果与分析 **3**

3.1 训练损失 3

3.2 生成样本 3

3.3 采样步数对比 4

4 问题、解决方法与总结 **4**

1 实验目的与数据

本实验从零实现一个用于 MNIST 手写数字生成的去噪扩散概率模型（DDPM）。实验重点不是追求分类意义上的“跑分”，而是验证扩散模型的前向加噪、噪声预测网络和反向生成链路，并分析反向采样步数对质量与速度的影响。

使用 torchvision 下载的 MNIST 训练集包含 60,000 张 28×28 灰度图像，像素经标准化后落在 $[-1, 1]$。本次训练共进行 20 个 epoch，批大小为 128，学习率为 2×10^{-4}，扩散步数为 1000，随机种子为 42。训练环境为 AutoDL 单张 NVIDIA GeForce RTX 3080 Ti；最终 checkpoint 记录了 9,380 个优化 step。

2 方法与软件实现

2.1 前向加噪

设 x_0 为真实图像，线性噪声日程定义为 $\beta_t \in [10^{-4}, 0.02]$，$\alpha_t = 1 - \beta_t$，$\bar{\alpha}_t = \prod_{s=1}^{t} \alpha_s$。利用闭式表达式直接采样：

$$q(x_t|x_0) = \mathcal{N}\left(\sqrt{\bar{\alpha}_t}x_0, (1-\bar{\alpha}_t)I\right), \qquad x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1-\bar{\alpha}_t}\,\epsilon, \tag{1}$$

其中 $\epsilon \sim \mathcal{N}(0, I)$。这避免了逐步执行前向马尔可夫链。

2.2 去噪网络与损失

去噪器是时间条件 Tiny U-Net，使用正弦时间嵌入、残差块、GroupNorm、SiLU 激活和跳跃连接。实际可训练参数量为 670,561，满足不超过 5M 的要求。训练目标为预测加入图像的噪声：

$$\mathcal{L} = \mathbb{E}_{x_0,t,\epsilon}\left[\|\epsilon - \epsilon_\theta(x_t, t)\|_2^2\right]. \tag{2}$$

2.3 反向 ancestral sampling

推理时从 $x_T \sim \mathcal{N}(0, I)$ 开始，依据网络预测噪声逐步计算 x_{t-1}，除最后一步外加入后验方差对应的随机噪声。程序实现了完整 1000 步采样，并实现了从同一条 1000 步噪声日程均匀抽取 200 或 50 个时间点的跳步 ancestral sampling。

3 实验结果与分析

3.1 训练损失

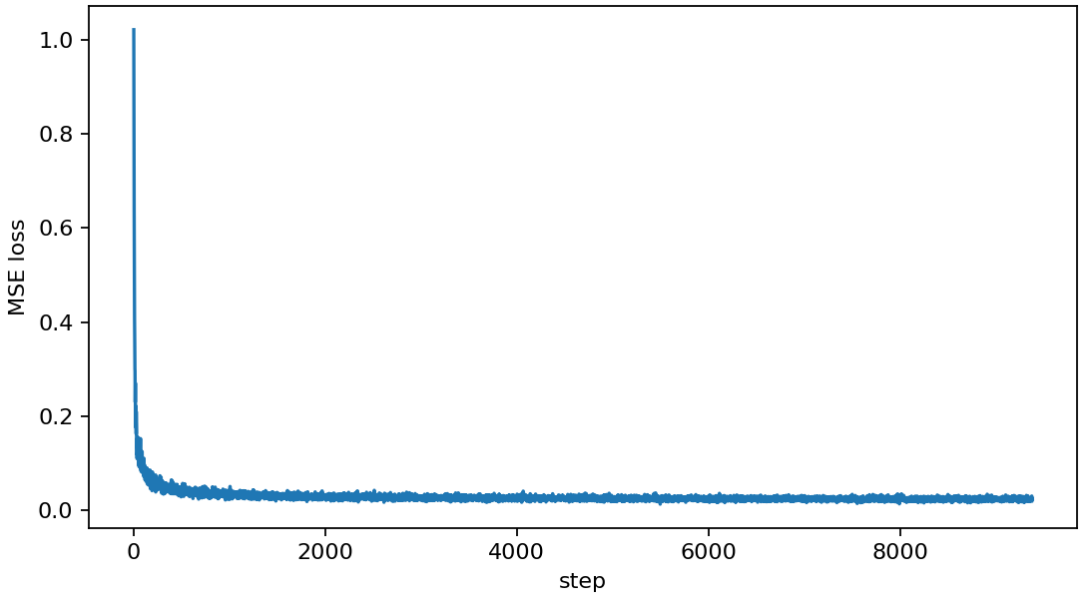


图 1: 20 个 epoch 的 MSE 噪声预测损失曲线。

如图 1 所示，损失在训练初期快速下降，随后在约 0.02–0.04 附近波动并趋于稳定，说明网络已经学会了基本的噪声估计。后期仍存在小幅随机波动，这是随机抽取时间步和训练 batch 带来的正常现象。

3.2 生成样本



图 2: 完整 1000 步反向采样得到的 8×8 样本网格。

样本整体能够呈现 MNIST 数字的笔画结构，说明模型已经完成从高斯噪声到数字图像分布的迁移。但部分数字仍有变形、粘连和类别边界不清晰的问题，表明在较小网络和有限训练轮数下，生成质量仍有提升空间。

3.3 采样步数对比

为便于复现实验，本地 CPU 上对同一 checkpoint、同一批 64 个样本进行测量，结果如表 1。实际训练和服务器推理使用 AutoDL 单张 RTX 3080 Ti；耗时会受到硬件、CUDA 版本和线程设置影响，因此表中重点关注相对趋势。

表 1: 不同反向采样步数的耗时对比（CPU，64 张图）。

采样步数	总耗时/s	每张图/s	相对 1000 步耗时
1000	58.1132	0.9080	100%
200	12.2095	0.1908	21.0%
50	2.9715	0.0464	5.1%



(a) 1000 步 (b) 200 步 (c) 50 步

图 3: 不同采样步数下的生成样本。

从图 3 可以看到，1000 步样本的笔画相对完整，200 步仍能保持大部分数字结构，而 50 步虽然速度最快，但更容易出现断笔、模糊和形状异常。该结果体现了扩散采样中质量与推理成本之间的典型折中：从 1000 步降到 50 步，速度约提升 19.6 倍，但质量有明显损失。服务器 GPU 上的绝对时间会更短，不过三种设置的相对比较仍具有参考价值。

4 问题、解决方法与总结

实验中首先遇到时间条件残差块调用参数遗漏的问题，导致模型前向传播报错；补齐各层的时间嵌入后解决。随后发现部分 PyTorch 版本不支持顶层 ‘torch.silu‘ 接口，改用 ‘torch.nn.functional.silu‘ 提高了兼容

性。另一个需要注意的问题是，200/50 步对比不能简单重新构造一条 50 步噪声日程，否则模型训练时的时间语义会改变；本实验采用训练好的 1000 步日程均匀跳步，比较更公平。

本实验验证了 DDPM 从数据预处理、前向扰动、噪声预测到反向生成的完整流程。结果表明，小型 U-Net 已能生成可辨认的 MNIST 数字；采样步数是影响推理速度的直接因素，实际应用中可根据质量要求选择 200 步或进一步采用 DDIM 等确定性加速方法。